

第一章 線形代数

1. 基本概念

- ・ベクトル・・・大きさと向きを持つ
- ・行列・・・ベクトルを並べたもの
- ・行列とベクトルの計算・・・行列の1行目とベクトルをかけて、1つ目の結果（上の要素）を作る。
行列の2行目とベクトルをかけて、2つ目の結果（下の要素）を作る。
- ・連立方程式の研究の中から生まれた！⇒行列を使った形式で表すことができる

2. 行列と計算

- ・行基本変形＝連立方程式を解くための計算を、行列の形で系統的にやるため方法
- ・行基本変形は行列の変形と言い換えることができる
- ・式 $AA^{-1} = A^{-1}A = I$ は逆行列の定義
- ・逆行列は掛けると左側が単位行列になる行列
- ・単位行列は、対角線上の要素がすべて1で、それ以外の要素がすべて0になっている正方行列
- ・逆行列が存在しない条件・・・解がない、解が1組に定まらないタイプの連立方程式

4. 行列式 (determinant)

- ・行列式・・・ある行列が2つの横ベクトルの組み合わせだと考えたときでつくられる平行四辺形の面積
- ・行列式の特徴・・・同じ行ベクトルが含まれていると行列式はゼロ
1つのベクトルが λ 倍されると行列式は λ 倍される
他の成分が全部同じで i 番目のベクトルだけが違った場合・・・行列式の足し合わせになる

5. 固有値・固有ベクトル

- ・固有値とベクトル・・・ $Ax = \lambda x$ ベクトル x とその係数 λ を、行列 A に対する、固有ベクトル、固有値という。
- ・固有値分解・・・正方形の行列を上述の様な3つの行列の積に変換すること

6. 特異値分解（SVD）

- ・ 特異値・・・行列がどれだけデータを「伸ばしたり縮めたり」するかを表す指標
- ・ 特異値分解・・・複雑な行列を、意味のある3つの行列に分解して理解しやすくする手法

第二章 確率・統計

1. 確率

確かさの率

- ① 頻度確率・・・発生する頻度（何度も測定すれば決まるという考え方、客観確率）
- ② ベイズ確率・・・信頼の度合い（気持ちの度合いを数字で表すという考え方、主観確率）

2. 条件付き確率・独率

- ・ 条件付き確率

ある事象 $X=x$ が与えられた下で、 $Y=y$ となる確率

ある事象 A が起こる確率を、別の事象 B が起こったという条件のもとで考えると以下の数式で表す

$$\begin{aligned} P(A|B) &= \frac{P(A \cap B)}{P(B)} \\ &= \frac{n(A \cap B)}{n(B)} \end{aligned}$$

- ・独立な事象の同時確率

お互いの発生には因果関係のない事象 $X=x$ と事象 $Y=y$ が同時に発生する確率

$$\begin{aligned} P(A \cap B) &= P(A)P(B|A) \\ &= P(A)P(B) \end{aligned}$$

- ・AまたはBで発生する確率

$$\begin{aligned} P(A \cup B) \\ &= P(A) + P(B) - P(A \cap B) \end{aligned}$$

- ・ベイズ則・・・ある事象の確率を、別の情報（条件）が与えられたときに更新するための法則

3.記述統計と推測統計

記述統計・・・集団の性質を要約し、記述する

推測統計・・・集団から一部を取り出し、元の集団（母集団）の性質を推測する

4.確率変数と確率分布

- ・確率変数・・・事象と結び付けられた数値。事象そのものを指すと解釈す。る場合も多い
- ・確率分布・・・事象の発生する確率の分布。離散値であれば表に示せる。

5.期待値・分散・共分散

- ・期待値・・・その分布における平均の値 or 「ありえそう」な値

$$\begin{array}{ll} \text{期待値} E(f) & \text{連続する値なら...} \\ = \sum_{k=1}^n P(X=x_k) f(X=x_k) & \text{期待値} E(f) \\ & = \int P(X=x) f(X=x) dx \end{array}$$

- ・分散と共分散
- ・分散・・・データの散らばり具合。データの各々の値が、期待値からどれだけズレているのか平均したもの

$$\begin{array}{l} \text{分散} \text{Var}(f) \\ = E \left(\left(f_{(X=x)} - E(f) \right)^2 \right) \\ = E \left(f_{(X=x)}^2 \right) - \left(E(f) \right)^2 \end{array}$$

- ・共分散・・・2つのデータ系列の傾向の違い。正の値を取れば似た傾向。負の値を取れば逆の傾向。ゼロを取れば関係性に乏しい。

$$\begin{array}{l} \text{共分散} \text{Cov}(f, g) \\ = E \left(\left(f_{(X=x)} - E(f) \right) \left(g_{(Y=y)} - E(g) \right) \right) \\ = E(fg) - E(f)E(g) \end{array}$$

- ・分散と標準偏差
- ・分散は2乗しているもので元のデータと単位が違う。
- ・2乗することの逆演算（つまり平方根を求める）をすれば元の単位に戻る。

・様々な分布①

・ベルヌーイ分布・・・コイントスのイメージ。裏と表で出る割合が等しくなくとも扱える。

$$P(x|\mu) = \mu^x(1-\mu)^{1-x}$$

・マルチヌーイ（カテゴリーカル）分布・・・さいころを転がすイメージ。各面の出る割合が等しくなくとも扱える。

・様々な分布②

・二項分布・・・ベルヌーイ分布の多試行版。真ん中辺りが一番大きい。

$$P(x|\lambda, n) = \frac{n!}{x!(n-x)!} \lambda^x (1-\lambda)^{n-x}$$

・ガウス分布・・・釣鐘型の連続分布。真の分布がわからなくてもサンプルが多ければ正規分布に近づく。

$$\mathcal{N}(x; \mu, \sigma^2) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$$

6.推定

- ・ 推定・・・母集団を特徴づける母数（パラメタ：平均など）を統計学的に推測すること。
- ・ 推定値は使い分けしている
- ・ 推定量・・・パラメータを推定するために利用する数値の計算方法や計算式のこと。推定関数とも。
- ・ 推定値・・・実際に施行を行った結果から計算した値
- ・ 真の値を θ とすると・・・ θ のようにあらわす。

- ・ 標本平均・・・母集団から取り出した標本の平均値
- ・ サンプル数が大きくなれば、母集団の値に近づく⇒一致制
- ・ サンプル数がいくらであっても、その期待値は母集団の値と同様⇒普遍性

$$E(\hat{\theta}) = \theta$$

- ・ 標本分散・・・サンプルサイズの中のデータのばらつき具合
一致制は満たすが、普遍性は満たさない。

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- ・ 不変分散・・・標本（サンプル）から母集団全体のばらつき（母分散）をより正確に推定するために使われる統計量

$$s^2 = \frac{n}{n-1} \times \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

※n-1はn個サンプルが無いと考えた方が良くと判断。

7.情報量

- ・ 自己情報量・・・ある特定の事象が発生したときに得られる「驚き」や「新規性」の度合いを数値化したもの
 - 対数の底が2の時、単位はビット (bit)
 - 対数の底がネイピアのeの時、単位は (nat)

$$I(x) = -\log(P(x)) = \log(W(x))$$

- ・ シャノンエントロピー・・・自己情報量の期待値

$$\begin{aligned} H(x) &= E(I(x)) \\ &= -E(\log(P(x))) \\ &= -\sum(P(x) \log(P(x))) \end{aligned}$$

- ・ カルバック・ライブラー ダイバージェンス
 - 同じ事象・確率変数における異なる確率分布P、Qの違いを表す

$$D_{KL}(P||Q) = \mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right] = \mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)]$$

- ・ 交差エントロピー
 - KL (カルバックライブラー) ダイバージェンスの一部を取り出したもの
 - Qについての自己情報量をPの分布で平均している。

第三章 情報理論

1. 自己情報量

- ・ 自己情報量・・・ある特定の事象が発生したときに得られる「驚き」や「新規性」の度合いを数値化したもの
 - 対数の底が2の時、単位はビット (bit)
 - 対数の底がネイピアのeの時、単位は (nat)

$$I(x) = -\log(P(x)) = \log(W(x))$$

- ・ シャノンエントロピー・・・自己情報量の期待値

$$\begin{aligned} H(x) &= E(I(x)) \\ &= -E(\log(P(x))) \\ &= -\sum(P(x) \log(P(x))) \end{aligned}$$

- ・ カルバック・ライブラー ダイバージェンス
 - 同じ事象・確率変数における異なる確率分布P、Qの違いを表す

$$D_{KL}(P||Q) = \mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right] = \mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)]$$

- ・ 交差エントロピー

→KL (カルバックライブラー) ダイバージェンスの一部を取り出したもの

→Qについての自己情報量をPの分布で平均している。

※機械学習の分類問題で「正解 (真の確率分布)」と「モデルの予測 (予測確率分布)」がどれだけズレているか (誤差) を測るための損失関数

$$D_{\text{KL}}(P\|Q) = \sum_x P(x) (-\log(Q(x))) - (-\log(P(x)))$$
$$H(P, Q) = H(P) + D_{\text{KL}}(P\|Q)$$
$$H(P, Q) = -\mathbb{E}_{x \sim P} \log Q(x) = -\sum_x P(x) \log Q(x)$$

2. 自己情報とエントロピー

- ・ 自己情報量[bit] : $I(x) = -\log_2(p(x))$

→特定の事象が持つ情報量を定量化した値

→直感的には、事象を観測した時の驚きの度合いの大きさを表す

- ・ エントロピー[bit] : $H = -\sum_{x \in X} p(x) \log_2(p(x))$

→事象全体の「自己情報量の期待値」

→直感的には、事象全体の不確実性の大きさや予測の難しさを表す

3. 相互情報量

- ・ 相互情報量[bit] : $I(X; Y) = \sum_{x \in X, y \in Y} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)}$

→事象Xの観測によって、事象Yの不確実性 (エントロピー) を減少させられる

→直観的には、事象XとYの依存度合いや影響の度合いを表す。

4.条件付きエントロピーと結合エントロピー

・条件付きエントロピー[bit]： $H(X,Y) = -\sum_{x \in X, y \in Y} p(x,y) \log_2 p(x,y)$

→事象Xが観測された上で残った事象Yの不確実性（エントロピー）

→直観的には、事象Xを知った上での事象Yの予測の難しさを表す。

・結合エントロピー[bit]： $H(X,Y) = -\sum_{x \in X, y \in Y} p(x,y) \log_2 p(x,y)$

→2つ以上の事象が同時に発生する全てのパターンの不確実性（エントロピー）の総和

→直観的には、2つ以上の事象の全ての同時発生パターンの多様性や不確実さを表す。

5.JSダイバージェンス

・JSダイバージェンス・・・2つの確率分布の類似性を測る尺度

→2つの確率分布の位置が近く、かつ形状が類似していれば値が小さく、異なれば値が大きくなる（0~1の範囲）

→類似性を測る尺度である「KLダイバージェンス」に基づくが、KLダイバージェンスと比べて下記の違いがある。

対称性：類似性を測る際の基準となる確率分布を入れ替えても同じ値となる

値が有限：無限大に発散することがなく、値が0~1.0に収まる（底が2の場合）

$$JS(P\|Q) = \frac{1}{2}KL(P\|M) + \frac{1}{2}KL(Q\|M)$$

6. KLダイバージェンス

- ・ KLダイバージェンス・・・2つの確率分布の類似性を測る尺度

→2つの確率分布の位置が近く、かつ形状が類似していれば値が小さく、異なれば値が大きくなる（0以上）

→JSダイバージェンスが2つの確率分布の距離や形状の違いを評価するイメージである一方で、KLダイバージェンス

は一方の確率分布をもう一方の確率分布で近似した情報損失を表すイメージ

→JSダイバージェンスと比べて下記の違いがある。

非対称性：類似性を測る際の基準となる確率分布を入れ替えると値が異なる

値が有限ではない： $P(x) > 0$ かつ $Q(x) = 0$ の条件で、KLダイバージェンスの値は無限大になる。

$$KL(P \parallel Q) = \sum_x P(x) \log_2 \left(\frac{P(x)}{Q(x)} \right)$$

7. クロスエントロピーとKLダイバージェンス

- ・ クロスエントロピー：2つの確率分布のエントロピーを測る尺度

2つの確率分布PとQにおいて、Pの分布をQの分布がどの程度正確に表現（近似）できているかを示す。

PでQを正確に表現できていれば値が小さくなり、表現できていなければ値が大きくなる

$$H(P, Q) = - \sum_x P(x) \log_2 Q(x)$$

8. クロスエントロピーとKLダイバージェンスの関係性

クロスエントロピー・KLダイバージェンスは、ともに2つの確率分布の類似性を測る尺度と捉えることができ、密接な関係性を持つ
KLダイバージェンスは、2つの確率分布 $P \cdot Q$ が与えられた場合、下記式より算出可能

$$KL(P\|Q) = H(P, Q) - H(P)$$

式より、分布 P を分布 Q でどれだけ正確に表現（近似）できているかを定量的に評価可能

→クロスエントロピー $H(P, Q)$ は、 Q が P と完全に同じ場合に P のエントロピーとなり、結果としてKLは0（最小値）となる

→クロスエントロピーはKLと同様に機械学習の分野で頻繁に使用される（ P を真の分布、 Q を予測分布として、クロスエントロピーの値を最小化する）

9. 機械学習分野での応用例

- ・ クロスエントロピー

→Deep learningを用いた分類問題などで頻繁に使用される

- ・ KLダイバージェンス

→Deep learningを用いた画像生成などで頻繁に使用される