

第一章 機械学習の課題

・原理・概要

機械学習（Machine Learning）とは、画像・言語・音声・数値などの様々なデータの背景に潜むルールやパターンを獲得する手法。
コンピュータに大量のデータを「学習」させることでルールやパターンを獲得し、それらを基に未知のデータを予測・解析する

・訓練誤差と汎化誤差

訓練誤差（Training Loss）：学習（訓練）データに対する予測と正解の誤差。学習データに対してどの程度正確に予測できるかを示す値。
汎化誤差（Generalization Loss）：未知のデータに対する予測と正解の誤差。未知のデータに対してどの程度正確に予測できるかを示す値。
→誤差の計算方法はデータ形式や問題設定によって異なる。数値を予測する場合は、正解値と予測値の差分などとなる。

・過剰適合の定義

過剰適合（Overfitting）：機械学習モデルが学習データに過剰に適合し、学習データに対しては高い精度な一方、未知のデータに対しては十分な精度が得られない現象。学習データの数に対してモデルの能力が過剰に高い（パラメータ数が多い）場合に主に発生する。
→獲得したルール・パターンが学習データ特化のものになり汎用性がなくなる→汎化誤差が高くなる

・過少適合の定義

過少適合（Underfitting）：機械学習モデルが学習データに十分に適合できず、学習データおよび未知のデータに対して十分な精度が得られない現象
学習データの数に対して手法の能力が過剰に低い（パラメータ数が少ない）場合に主に発生する。

・過剰・過少学習の原因

過少適合の原因：データの分布に対してモデルの次元が小さすぎる（パラメータ数が少なすぎる）
過剰適合の原因：データの分布に対してモデルの次元が大きすぎる（パラメータ数が大きすぎる）or データ数が少なすぎる場合
→データ数とデータ分布の特性を観察した上で適切な次元のモデルを設定する必要がある

・データ数と過剰・過少適合の関係

データ数が少ない場合：過少適合が発生し、汎化誤差も大きくなる。過剰適合は、適切なモデルの次元であっても発生し、汎化誤差も大きくなる。
データ数が多い場合：過少適合は発生するが、汎化誤差はある程度小さくなる。過剰適合は、モデルの次元が過剰であっても抑制される

→一般的に、データ数が多ければ多いほど過少・過剰適合の問題は緩和される

- ・ 過剰・過少適合が引き起こす問題

過剰・過少適合が発生すると、未知のデータに対するモデルの予測が不正確になる。

→過少・過剰適合したモデルでは、正解値と予測値の誤差が大きく不正確な結果となる

- ・ 正則化の定義と目的

正則化（Regularization）：機械学習モデルの過剰適合を抑制する方法。モデルのパラメータが複雑になりすぎないように（学習データに特化しすぎないように）、制約を加えた状態で学習させる。正則化の方法は様々であり、解きたい問題や手法によって異なる。

→パラメータの値が大きくなると正則化項の値も大きくなる→指標を最小化するためにはパラメータの値を小さくする必要あり

→モデルが複雑になりすぎるのが抑制される→過剰適合が抑制され汎化性能が上がる

- ・ 次元の呪い

次元の呪い（The curse of dimensionality）：機械学習において、特徴量の次元の数が大きくなればなるほど正確に適合するモデルの作成に必要なデータ数が指数関数的に増加し、結果として学習が難しくなる現象。

- ・ 深層学習の概要

深層学習（Deep learning）：機械学習の手法の1つ。人間の神経細胞を模倣した機械学習手法「ニューラルネットワーク」において、層の数を増やして多層にしたものを深層学習と呼ぶ。他の機械学習手法と比べて、特徴量の設計が必要なく高精度などのメリットを持つ。

- ・ 一般的な機械学習手法・・・線形回帰、SVM、ランダムフォレストなど
- ・ 深層学習手法・・・深層学習の多数の層により、入力から自動的に特徴量が獲得される

- ・ 深層学習のメリット

- ・ 入力から自動的に特徴量を獲得できるため、人手による特徴量設計の負担がなくなる
- ・ （十分な学習データの数がある場合）人手による特徴量よりも高度な特徴量を獲得でき、結果的に高精度な予測が可能となる

- ・ 深層学習のデメリット

- ・ 高度な特徴量獲得のためには数万～数十万規模のデータセットが必要となり、データセット収集の負荷が大きい
- ・ 学習にはGPUなどの計算資源が必要であり、かつ学習時間もかかる

- ・ 深層学習における過剰・過少適合

深層学習でも、他の機械学習手法と同様に過剰・過少適合が発生する。深層学習では、学習時にモデルのパラメータを繰り返し更新する（繰り返し回数=エポック数）が、その際の訓練誤差・汎化誤差の状況から過剰・過少適合を判定可能。

- ・ 深層学習の学習

- ・ あらかじめ設定した繰り返し回数分（=エポック数）、反復的にパラメータ（ニューロンの重みなど）を更新する
- ・ 訓練誤差と汎化誤差の状況をリアルタイムに観察する
- ・ 訓練データの数 > 検証データの数であるため、通常は訓練誤差の方が汎化誤差よりも低い値となる

- ・ 深層学習の学習状況の見方

①過少適合：訓練誤差と汎化誤差の傾向は同じだが、汎化誤差の方が値が明らかに大きい。モデルのパラメータ数を増やして、乖離を小さくすることで抑制可能。

②過剰適合：訓練誤差と汎化誤差の傾向が異なり、訓練誤差と汎化誤差の乖離が大きくなっていく。訓練誤差に特化したモデルになっていることを示しており、正則化やモデルのパラメータ数を減らすなどで抑制可能。

→反復的な学習の中で、過少→過剰適合へと変化している。

グラフの状況から適合状況を見極め、正則化やモデルのパラメータ数を調整して対応する必要がある

機械学習モデリングプロセス（プロセスは深層学習でも同じ）

1. 問題設定・・・どのような課題を機械学習に解決させるか。←一番大事なところはこちらかもしれない。
2. データ設定・・・どのようなデータを使うか
3. データの前処理・・・モデルに学習させられるようにデータを変換
4. 機械学習モデルの設定・・・どの機械学習モデルを利用するか。
5. モデルの学習（パラメータ推定）
6. モデルの評価・・・ハイパーパラメータの選定。モデル制度を測る。

※GIGO・・・「誤ったデータを入力すれば、誤った結果が出てくる」という意味
 入力がゴミなら、出力もゴミになる
 どれだけ高性能なコンピューターでも、間違ったデータを正しくはしてくれない
 機械学習・データ分析では特に重要な原則

第二章 性能指標

性能指標・・・モデルの予測精度を定量的に評価するための指標。分類・回帰タスクごとにさまざまな性能指標がある。

	分類タスク		回帰タスク
	(2値分類)	(多値分類)	
予測対象	種類 (2クラス)	種類 (3クラス以上)	連続値
評価基準	正解した割合		正解との誤差
性能指標	混同行列		MSE/RMSE MAE 決定係数
	ROC曲線 AUC 正解率 (Accuracy) 適合率 (Precision) 再現率 (Recall) F値	micro平均/macro平均	

分類タスクの予測結果をまとめた混同行列から、正解率と適合率、再現率、F値の評価指標が計算できる。

- ・ 正解率・・・全データ数のうち、予測が実際に当たった数の割合。クラスの偏りに影響を受けやすい
- ・ 適合率・・・陽性と予測したデータのうち、実際に陽性だった数の割合。誤って陽性と予測する数に注目
- ・ 再現率・・・実際の陽性データ数のうち、正しく陽性と予測した割合。実際の陽性を予測で見落とす数に注目
- ・ F値・・・適合率と再現率のバランスをとった評価指標。クラスの数の偏りに影響を受けにくい。

混同行列

	実際は陽性	実際は陰性
予測は陽性 (Positive)	TP (True Positive) 真陽性	FP (False Positive) 偽陽性
予測は陰性 (Negative)	FN (False Negative) 偽陰性	TN (True Negative) 真陰性

性能指標

名称	計算方法
正解率 (Accuracy)	$\frac{TP + TN}{TP + FP + FN + TN}$
適合率 (Precision)	$\frac{TP}{TP + FP}$
再現率 (Recall)	$\frac{TP}{TP + FN}$
F値	$\frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$

- ・ ROC曲線・・・分類予測の正確性を視覚的に示し、AUCから定量評価できる性能指標。
→ 左上の辺に近いモデルが理想。直線だとランダムなモデルと同じ。
- ・ AUC・・・ $AUC = 1$: 正確に判断するモデル。 $AUC = 0.5$: ランダムに判断するモデル。
- ・ 多クラス分類タスクにおける性能指標には、micro平均とmacro平均がある。

混同行列

	実際はA	...	実際はN
推論はA	True	...	False
⋮	⋮	⋮	⋮
推論はN	False	...	True



■ micro平均

- 全クラスの予測結果を合計
- クラス数の偏りに影響

■ macro平均

- クラスごとの性能指標を平均
- クラスごとの比重は同じ

性能指標

			$i: 1 \sim N$		名称	計算方法
	実際は X_i	実際は X_i 以外			micro平均 (適合率)	$\frac{\sum_i^N TP_i}{\sum_i^N TP_i + FP_i}$
推論は X_i	TP_i	FP_i			macro平均 (適合率)	$\frac{1}{N} \sum_i^N \frac{TP_i}{TP_i + FP_i}$
推論は X_i 以外	FN_i	TN_i		平均		

・ 回帰タスクで用いられる性能指標には、MSE/RMSEとMAE、決定係数がある。

MSE（平均二乗誤差）・・・0ほど誤差が小さい。誤差の単位が2乗

RMSE（平均平方二乗誤差）・・・0ほど誤差が小さい。誤差の単位が同じ。

MAE（平均絶対誤差）・・・0ほど誤差が小さい。外れ値の影響が小さい。

決定係数・・・0～1の値を取る。1ほど精度が高い。

性能指標

y : 予測値、 t : 実際の値、 $\bar{y}$: 予測値の平均

名称	計算方法
MSE (Mean Squared Error)	$\frac{1}{N} \sum_i^N (y_i - t_i)^2$
RMSE (Root Mean Squared Error)	$\sqrt{\frac{1}{N} \sum_i^N (y_i - t_i)^2}$
MAE (Mean Absolute Error)	$\frac{1}{N} \sum_i^N y_i - t_i $
決定係数	$1 - \frac{\sum_i^N (y_i - t_i)^2}{\sum_i^N (y_i - \bar{y})^2}$

第三章 線形回帰モデル

- ・ 回帰問題・・・ある入力（離散あるいは連続値）から出力（連続値）を予測する問題

直線で予測→線形回帰

曲線で予測→非線形回帰

- ・ 回帰で扱うデータ

入力・・・m次元のベクトル（m = 1 の場合はスカラー）

出力・・・スカラー値（目的変数）

説明変数	$\mathbf{x} = (x_1, x_2, \dots, x_m)^T \in \mathbb{R}^m$
目的変数	$y \in \mathbb{R}^1$

- ・ 線形回帰モデル

回帰問題を解くための機械学習モデルの一つ

教師あり学習（教師データから学習）

入力とm次元パラメータの線形結合を出力するモデル

→慣例として予測値にはハットを付ける（正解データとは異なる）。

パラメータ	$\mathbf{w} = (w_1, w_2, \dots, w_m)^T \in \mathbb{R}^m$
線形結合	$\hat{y} = \mathbf{w}^T \mathbf{x} + w_0 = \sum_{j=1}^m w_j x_j + w_0$

- ・ 線形結合（入力とパラメータの内積）

モデルに含まれる推定すべき未知のパラメータ

特徴量が予測値に対してどのように影響を与えるかを決定する重みの集合

- 正の（負の）重みを付ける場合、その特徴量の値を増加させると、予測の値が増加（減少）
- 重みが大きければ（0であれば）、その特徴量は予測に大きな影響力を持つ（全く影響しない）
- y 軸との交点を表す。

$$\hat{y} = \underline{\mathbf{w}}^T \mathbf{x} + \underline{w_0} = \sum_{j=1}^m \underline{w_j} x_j + \underline{w_0}$$

パラメータは未知


最小二乗法により推定

※wが変わることは傾きが変わるということ

- ・説明変数が1次元の場合（m = 1）→単回帰モデルと呼ぶ
- ・データへの仮定→データは回帰直線に誤差が加わり観測されていると仮定



- ・説明変数が多次元の場合（m > 1）→線形重回帰モデル。単回帰は直線、重回帰は曲線
- ・データへの仮定・・・データは回帰局面に誤差が加わり観測されていると仮定



- ・連立方程式・・・それぞれのデータをモデル式へ当てはめると n 個の式が導出される。

連立方程式	未知パラメータ	行列表現	
$y_1 = w_0 + w_1 x_1 + \varepsilon_1$ $y_2 = w_0 + w_1 x_2 + \varepsilon_2$ $y_n = w_0 + w_1 x_n + \varepsilon_n$		$\mathbf{y} = X\mathbf{w} + \boldsymbol{\varepsilon}$ $\mathbf{y}$ = X $\mathbf{w}$	$X = (\mathbf{x}_1, \dots, \mathbf{x}_n)^T$ $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$ $\mathbf{x}_i = (1, x_i)^T$ $\boldsymbol{\varepsilon} = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)^T$ $\mathbf{w} = (w_0, w_1)^T$

- ・ データの分割とモデルの汎化性能測定
- ・ データの分割
 - 学習用データ 機械学習モデルの学習に利用するデータ
 - 検証用データ 学習済みモデルの性能を検証するためのデータ
- ・ なぜ分割するか
 - モデルの汎化性能を測定するため
 - データへの当てはまりの良さではなく、未知のデータに対してどれくらい性能が高いかを図りたい
- ・ 機械学習モデルを検証用のデータを用いて測る
 - どのパラメータが妥当かを推定する。
- ・ 線形回帰モデルのパラメータは最小二乗法で推定
- ・ 平均二乗誤差（残差平方和）
 - データとモデル出力の二乗誤差の和・・・小さいほど直線とデータの距離が近い
 - パラメータのみに依存する関数・・・データは既知の値でパラメータのみ未知
- ・ 最小二乗法
 - 学習データの平均二乗誤差を最小とするパラメータを探索
 - 学習データの平均二乗誤差の最小化は、その後輩が0になる点を求めれば良い。

$$\text{MSE}_{\text{train}} = \frac{1}{n_{\text{train}}} \sum_{i=1}^{n_{\text{train}}} (\hat{y}_i^{(\text{train})} - y_i^{(\text{train})})^2$$

- ・ 回帰の場合には最尤法による解は最小二乗法の解と一致

第四章 非線形回帰モデル

- ・ 複雑な非線形構造を内在する現象に対して、非線形回帰モデリングを実施
 - データの構造を線形で捉えられる場合は限られる
 - 非線形な構造を捉えられる仕組みが必要
- ・ 回帰関数として、基底関数と呼ばれる既知の非線形関数とパラメータベクトルの線形結合を使用
- ・ 未知パラメータは線形回帰モデルと同様に最小2乗法や最尤法により推定

$$y_i = f(\mathbf{x}_i) + \varepsilon_i \quad \rightarrow \quad y_i = w_0 + \sum_{j=1}^m w_j \phi_j(\mathbf{x}_i) + \varepsilon_i$$

線形 非線形に変換

- ・ よく使われる基底関数
 - 多項式関数
 - ガウス型基底関数
 - スプライン関数/ Bスプライン関数
- ・ 1次元の基底関数に基づく非線形回帰

多項式 (1~9次)

$$f(x) = \sum_{j=0}^m a_j x^j$$

ガウス型基底

$$f(x) = \sum_{j=1}^m w_j \exp \left[-\frac{1}{2} (x - \mu_j)^2 \right]$$

$$\phi_j = x^j$$

$$\phi_j(x) = \exp \left\{ -\frac{x^2}{2h_j} \right\}$$

※正規分布形そのもの

- ・2次元の基底関数に基づく非線形回帰

2次元ガウス型基底関数

$$\phi_j(\mathbf{x}) = \exp \left\{ -\frac{(\mathbf{x} - \boldsymbol{\mu}_j)^T (\mathbf{x} - \boldsymbol{\mu}_j)}{2h_j} \right\}$$

※Hjが低くなるとバンド幅が小さくなりHjが高くなるとバンド幅が広がる

- ・基底展開法も線形回帰と同じ枠組みで推定が可能

説明変数

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{im}) \in \mathbb{R}^m$$

非線形関数ベクトル

$$\boldsymbol{\phi}(\mathbf{x}_i) = (\phi_1(\mathbf{x}_i), \phi_2(\mathbf{x}_i), \dots, \phi_k(\mathbf{x}_i))^T \in \mathbb{R}^k$$

非線形関数の計画行列

$$\Phi^{(train)} = (\boldsymbol{\phi}(\mathbf{x}_1), \boldsymbol{\phi}(\mathbf{x}_2), \dots, \boldsymbol{\phi}(\mathbf{x}_n))^T \in \mathbb{R}^{n \times k}$$

最尤法による予測値

$$\hat{\mathbf{y}} = \Phi (\Phi^{(train)T} \Phi^{(train)})^{-1} \Phi^{(train)T} \mathbf{y}^{(train)}$$

- ・未学習(underfitting)と過学習(overfitting)

学習データに対して、十分小さな誤差が得られないモデル→未学習

→対策として表現力の高いモデルを使用する。

小さな誤差は得られたけど、テスト集合誤差との差が大きいモデル→過学習

→対策として①学習データの数を増やす。②不要な基底関数を削除③ 正則化法を利用

- ・不要な基底関数を削除

基底関数の数、位置やバンド幅によりモデルの複雑さが変化

解きたい問題に対して多くの基底関数を用意してしまうと過学習の問題がおこるため、適切

な基底関数を用意(CVなどで選択)

- ・ 正則化法(罰則化法)

「モデルの複雑さに伴って、その値が大きくなる正則化項(罰則項)を課した関数」を最小化
正則化項(罰則項)・・・形状によっていくつもの種類があり、それぞれ推定量の性質が異なる
正則化(平滑化)パラメータ・・・モデルの曲線のなめらかさを調節

- ・ 正則化項(罰則項)の役割

→無い⇒最小2乗推定量
→L2ノルムを利用Ridge→推定量→L1ノルムを利用Lasso推定量
→L1ノルムを利用→Lasso推定量

- ・ 汎化性能 ■ 汎化誤差は通常、学習データとは別に収集された検証データでの性能を測ることで推定 ○ バイアス・バリエンス分解

学習に使用した入力だけでなく、これまで見たことのない新たな入力に対する予測性能
→(学習誤差ではなく)汎化誤差(テスト誤差)が小さいものが良い性能を持ったモデル。
→汎化誤差は通常、学習データとは別に収集された検証データでの性能を測ることで推定

- ・ データの分割とモデルの汎化性能測定

→学習に使ったデータと別のデータで検証する。検証誤差にて性能測定を実施する。

- ・ 非線形モデル

手元のモデルがデータに未学習しているか過学習しているか確認する・
→訓練誤差もテスト誤差もどちらも小さい⇒汎化しているモデルの可能性
→訓練誤差は小さいがテストの誤差が大きいの⇒過学習の可能性
→訓練誤差もテスト誤差もどちらも小さくならない⇒未学習の可能性

- ・ ホールドアウト法・・・手元のデータを「学習用」と「評価用」に分けてモデルの性能を測る方法

有限のデータを学習用とテスト用の2つに分割し、「予測精度」や「誤り率」を推定するために使用
→学習用を多くすればテスト用が減り学習し精度は良くなるが、性能評価の精度は悪くなる。
→逆にテスト用を多くすれば学習用が減少するので、学習そのものの精度が悪くなることになる。

→手元にデータが大量にある場合を除いて、良い性能評価を与えないという欠点がある。

基底展開法に基づく非線形回帰モデルでは、基底関数の数、位置、バンド幅の値とチューニングパラメータをホールドアウト値を小さくするモデルで決定する。

- ・クロスバリデーション(交差検証)・・・「学習」と「評価」を何度も入れ替えて繰り返すことで、モデルの性能を安定して測る方法
 - 偶然のデータの偏りに左右されず、より信頼できる評価ができる
 - データが少なくても、すべてのデータを有効に使って評価できる
- ・グリッドサーチ・・・全てのチューニングパラメータの組み合わせで評価値を算出
 - 最も良い評価値を持つチューニングパラメータを持つ組み合わせを、「いいモデルのパラメータ」として採用
- ・ロジスティック回帰・・・分類問題で使用する。分類で扱うデータは入力（各要素を説明変数または特徴量と呼ぶ）と出力（目的変数：0 or 1)を使用
- ・ロジスティック線形回帰モデル・・・分類問題を解くための教師あり機械学習モデル(教師データから学習)
 - 入力とm次元パラメータの線形結合をシグモイド関数に入力
 - 出力は $y=1$ になる確率の値になる
- ・シグモイド関数・・・ 入力は実数・出力は必ず0~1の値、(クラス1に分類される)確率を表現、単調増加関数
- ・シグモイド関数の性質・・・シグモイド関数の微分は、シグモイド関数自身で表現することが可能。
尤度関数の微分を行う際にこの事実を利用すると計算が容易
- ・シグモイド関数の出力を $Y=1$ になる確率に対応させる
 - データの線形結合を計算し、シグモイド関数をかけて0～1の間で結果を出力する。
- ・尤度関数・・・データは固定し、パラメータを変化させる
- ・尤度関数を最大化するようなパラメータを選ぶ推定方法を最尤推定という
- ・ロジスティック回帰モデルの最尤推定
 - 確率 p はシグモイド関数となるため、推定するパラメータは重みパラメータとなる

$(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_1), \dots, (\mathbf{x}_n, y_n)$ を生成するに至った尤もらしいパラメータを探す。

- ・ 尤度関数を最大とするパラメータを探す(推定)

対数をとると微分の計算が簡単

→ 同時確率の積が和に変換可能。指数が積の演算に変換可能

対数尤度関数が最大になる点と尤度関数が最大になる点は同じ

→ 対数関数は単調増加(ある尤度の値が $x_1 < x_2$ の時、必ず $\log(x_1) < \log(x_2)$) となる

「尤度関数にマイナスをかけたものを最小化」し、「最小2乗法の最小化」と合わせる

- ・ 対数尤度関数を係数とバイアスに関して微分

$$\begin{aligned}\frac{\partial E(\mathbf{w})}{\partial \mathbf{w}} &= \sum_{i=1}^n \frac{\partial E_i(\mathbf{w})}{\partial p_i} \frac{\partial p_i}{\partial \mathbf{w}} \\ &= \sum_{i=1}^n \left(\frac{y_i}{p_i} - \frac{1-y_i}{1-p_i} \right) \frac{\partial p_i}{\partial \mathbf{w}} \\ &= \sum_{i=1}^n \left(\frac{y_i}{p_i} - \frac{1-y_i}{1-p_i} \right) p_i(1-p_i) \mathbf{x}_i \\ &= - \sum_{i=1}^n (y_i(1-p_i) - p_i(1-y_i)) \mathbf{x}_i \\ &= - \sum_{i=1}^n (y_i - p_i) \mathbf{x}_i\end{aligned}$$

連鎖律

対数尤度関数の
pに関する微分

シグモイド関数の微分

式を整理

- ・ パラメータが更新されなくなった場合、それは勾配が0になったということ。少なくとも反復学習で探索した範囲では最適な解がもとめられたことになる。

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} + \eta \sum_{i=1}^n (y_i - p_i) \mathbf{x}_i$$

- ・ 勾配降下法では、パラメータを更新するのにN個全てのデータに対する和を求める必要がある。

→ データを一つずつランダムに(「確率的」に)選んでパラメータを更新

→勾配降下法でパラメータを1回更新するのと同じ計算量でパラメータをn回更新できるので効率よく最適な解を探索可能

$$\mathbf{w}(k+1) = \mathbf{w}^k + \eta(y_i - p_i)\mathbf{x}_i$$

- ・学習済みの「ロジスティック回帰モデル」の性能を測る指標について見ていく。

その前に混同行列(confusion matrix)について説明

→各検証データに対するモデルの予測結果を4つの観点(表)で分類し、それぞれに当てはまる予測結果の個数をまとめた表

		検証用データの結果	
		positive	negative
モデルの 予測結果	positive	真陽性 (True Positive) - 正しく positive と判別した個数	偽陰性 (False Positive) -間違えて positive と判別した個数
	negative	偽陽性 (False Negative) -間違えて Negative と判別した個数	真陰性 (True Negative) - 正しく Negative と判別した個数

- ・分類の評価方法

→「正解率」がよく使われる

→正解した数/ 予測対象となった全データ数

例) メールのスパム分類

→どのような問題があるか？

分類したいクラスにはそれぞれ偏りがあることが多い

この場合、単純な正解率はあまり意味をなさないことがほとんど

$$\frac{TP + TN}{TP + FN + FP + TN}$$

- ・再現率(Recall)・・・「本当にPositiveなもの」の中からPositiveと予測できる割合

$$\frac{TP}{TP + FN}$$

- ・適合率(Precision)・・・モデルが「Positiveと予測」したものの中で本当にPositiveである割合

$$TP$$

$$\frac{TP}{TP+FP}$$

- ・ F値・・・理想的にはどちらも高いモデルがいいモデルだが、両者はトレードオフの関係にあり、どちらかを小さくすると、もう片方の値が大きくなってしまう。

第五章 主成分分析、K近傍法、Kmeans

- ・ 主成分分析
 - ・ 多変量データの持つ構造をより少数個の指標に圧縮
 - 変量の個数を減らすことに伴う、情報の損失はなるべく小さくしたい
 - 少数変数を利用した分析や可視化(2・3次元の場合)が実現可能
 - ・ 係数ベクトルが変われば線形変換後の値が変化
 - 情報の量を分散の大きさと捉える
 - 線形変換後の変数の分散が最大となる射影軸を探索
- ・ 以下の制約付き最適化問題を解く
ノルムが1となる制約を入れる(制約を入れないと無限に解がある)
 - ・ 制約つき最適化問題の解き方
 - ラグランジュ関数を最大にする係数ベクトルを探索(微分して0になる点)
 - ・ ラグランジュ関数を微分して最適解を求める
 - 元のデータの分散共分散行列の固有値と固有ベクトルが、上記の制約付き最適化問題の解とな
 - ・ 分散共分散行列は正定値対称行列固有値は 必ず 0以上・ 固有ベクトルは1次元PCA2次元PCA直行
 - ・ 寄与率・・・ 第1~次元成分の主成分の分散は、元のデータの分散と一
 - ・ 設定・・・ 乳がん検査データを利用しロジスティック回帰モデルを作成。 第k主成分の分散は主成分に対応する固有値
分散共分散行列は正定値対称行列固有値は 必ず 0以上・ 固有ベクトルは1次元PCA2次元PCA直行
 - 元のデータの分散共分散行列の固有値と固有ベクトルが、上記の制約付き最適化問題の解となる

- ・ k近傍法
- ・ k近傍法分類問題のための機械学習手法
 - 最近傍のデータを 個取ってきて、それらがもっとも多く所属するクラスに識別
 - kを変化させると結果も変わる
 - kを大きくすると決定境界は滑らかになる
- ・ k-means
- ・ 教師なし学習
- ・ クラスタリング手法
- ・ 与えられたデータをk個のクラスタに分類する
- ・ k平均法(k-means)のアルゴリズム
 - 各クラスタ中心の初期値を設定する
 - 各データ点に対して、各クラスタ中心との距離を計算し、最も距離が近いクラスタを割り当てる
 - 各クラスタの平均ベクトル（中心）を計算する
 - 収束するまで2, 3の処理を繰り返す次から各手順の詳細を説明す
- ・ k平均法(k-means)
 - kの値を変えるとクラスタリング結果も変化

第六章 パターン認識

- ・ k近傍法とその計算に用いられる距離計算方法と性質を理解し、データの特性に応じた距離の選択を行えるようにする。
- ・ K近傍法とその計算量
 - k近傍法は識別したいサンプルと訓練サンプル間の距離を計算しクラス分類をするアルゴリズム
 - サンプル間の距離計算の計算量が課題となる
 - いろいろな距離計算の方法や計算量を削減する工夫がなされている
- ・ 近似最近傍探索の必要性

高次元空間では、従来の方法で全てのデータ点との距離を計算するのはコストが高く、時間もかかる。

高速なデータフィルタリングと精度のバランスを取ることを目指す

- ・ 近似最近傍探索の必要性 近似最近傍探索のアプローチ

Tree/Partitioning ... kd木などの2分木を用いる方法

Graph探索... グラフ構造を用いて近傍を検索

Locality Sensitive Hashing (LSH; 局所鋭敏性ハッシュ) ... 類似したデータを同じバケットに割り当てるハッシュ関数のアプローチ
データの量子化

- ・ 近似最近傍探索の用途






k近傍法の距離計算

情報検索

画像認識

音声処

- ・ ベクトル・データ間の距離計算には様々な手法が存在し、用途に応じた距離が用いられていま

	コサイン距離	ユークリッド距離	マンハッタン距離	Lp距離	マハラノビス距離
模式図					
数式	$d(x, y) = 1 - \cos \theta$ $= 1 - \frac{x \cdot y}{\ x\ \ y\ }$	$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$	$d(x, y) = \sum_{i=1}^n x_i - y_i $	$d(x, y) = \sqrt[p]{\sum_{i=1}^n (x_i - y_i)^p}$	$d(x, y) = \sqrt{(x - y)^T S^{-1} (x - y)}$ S⁻¹: 共分散行列
	● 2つのベクトルがなす角のコサイン値	● いわゆる“通常の”距離 ● L₂距離とも呼ぶ	● 各座標における差の絶対値の総和	● L_p空間におけるL_p距離を一般化したもの	● 統計学で用いられる ● データの散らばりを考慮し、

説明			● L_1 距離とも呼ぶ	● 図は中心点からの距離が同じ個所を示したもの	データ群からの距離を示す
事例	● テキストマイニング ● 自然言語処理	● クラスタリング ● 画像処理 ● 特徴量の比較	● 特徴量の比較 ● ルート検索	● k近傍法の一般化 ● 特徴量の正規化 ● 次元削減	● 異常検知 ● 特徴量の選択